O ATENDIMENTO POR DENTRO

SecretarIA. Da conversa à consulta.

Como a clínica recebe, orienta e agenda.
A arquitetura que sustenta a experiência.
E quanto a inteligência realmente custa.

PREVISÃO CENTRAL · SOMENTE LLM POR CONSULTA MARCADA

R$ 0,0125

Cerca de **1,25 centavo** por agendamento.

Cenário ilustrativo com Haiku 5.5, 35% das conversas com IA e 60% de conversão. Inclui o gasto das conversas que não agendam. Não é média observada nem custo total da operação.

01 / EXPERIÊNCIA
Fluxo guiado e conversa livre

02 / ENGENHARIA
Serviços, dados e APIs

03 / ECONOMIA
Premissas e simulador

Base: checkout local de 28/10/2026. Valores em reais usam dólar hipotético de R$ 5,50; sem tributos e spread. Documento sobre agendamento, sem estimativa do custo do atendimento médico.

01 / A TESE

Automação como base. IA quando faz diferença.

A SecretarIA combina regras de agendamento com linguagem natural. Essa divisão explica tanto o funcionamento quanto a economia.

CAMINHO GUIADO

Escolher e confirmar

Botões, listas, perguntas fixas, catálogo e horários conduzem o paciente. O servidor valida escolhas e executa as ações.

R$ 0

de tokens de chat, se toda a jornada permanecer nesse caminho. Infraestrutura e canal continuam existindo.

CAMINHO CONVERSACIONAL

Entender e orientar

A IA responde a texto livre, usa os fatos da clínica e chama ferramentas permitidas. Pode devolver o paciente ao fluxo guiado.

Sob demanda

Uma fala do paciente pode provocar várias requisições ao modelo, especialmente ao consultar ferramentas.

> **A unidade econômica é a consulta marcada.** Para saber quanto cada uma custa, some também a IA consumida por quem tirou dúvidas, desistiu ou precisou de uma pessoa da equipe.

O que a clínica configura

Profissionais, serviços, preços, convênios, duração, expediente, fuso, orientações, contexto, agenda e política de sinal.

O que o paciente percebe

Uma conversa com continuidade: pode escolher, perguntar, voltar, alterar dados e gerenciar a própria consulta.

Roteiro de leitura

A jornada e a entrada da IA 03
Mapa da arquitetura 04
Integrações e APIs 06
A conta do Haiku 08
Simulador ajustável 10
Fontes e limites 13

Código confirmado: services/flow_router.py; workers/turn_router.py; workers/orchestrator.py; ai/graph.py; ai/scoped_help.py. O documento descreve o código encontrado; disponibilidade ao vivo depende de implantação e configuração.

02 / EXPERIÊNCIA DO PACIENTE

Uma jornada.
Dois modos de atender.

WhatsApp e Portal têm entradas diferentes e compartilham o núcleo de regras de agendamento.

1 **Entrar e identificar** — Sem chat LLM

WhatsApp recebe a mensagem da pessoa. O Portal recebe a visita ou a mensagem pelo brain-api. Nome, consentimento e verificação seguem a política do canal e da conta.

2 **Escolher o caminho** — Regras + IA

Saudação e menu reconhecem o contexto disponível. "Outro" pode começar com uma pergunta fixa; a IA entra na resposta livre da pessoa.

3 **Montar o agendamento** — Guiado

Beneficiário, convênio, profissional e serviço compõem a escolha, conforme configuração. Dados já informados podem ser preservados como rascunho.

4 **Escolher data e horário** — Agenda real

Expediente, duração, bloqueios e ocupação real determinam as opções. A IA ajuda a interpretar a intenção; disponibilidade vem do serviço de agenda.

5 **Revisar, verificar e confirmar** — Transacional

O sistema aplica os portões necessários: confirmação, identidade e, quando configurado, sinal. No modo Pix "antes", há reserva temporária e a consulta nasce após identificar o pagamento.

6 **Acompanhar e gerenciar** — Automação

Confirmação, notificações, lembretes e ações de remarcar/cancelar são orquestrados pelo servidor. A clínica pode assumir o atendimento humano.

> **Nem todo texto livre usa a mesma IA.** Há ajuda delimitada para escolher profissional/serviço e há o agente completo, com histórico e ferramentas. Ambos podem gerar tokens; clicar em um botão não implica uma chamada por si só.

Fontes: flow_router.py; ai/scoped_help.py; services/booking_promotion.py; services/payments/fulfillment.py; workers/portal/; workers/whatsapp/. Ordem e portões dependem das opções habilitadas. Não se reproduziu uma jornada de produção nesta análise.

03 / VISÃO DE SISTEMA

O mapa que conecta paciente, clínica e agenda.

A API recebe. A fila desacopla. O worker decide e executa. O banco preserva o estado.



> **brain-api é o centro do ecossistema.** Identidade, assinatura, permissões e intermediação entre produtos passam por ele. O encaminhamento ao PreCheck sai da SecretarIA para o brain-api, que coordena o outro produto.

A agenda já pode ser nativa. Sem credencial Google aplicável, o código seleciona a agenda local. Uma credencial Google revogada gera falha e reconexão; ela não troca silenciosamente para a agenda local, o que evitaria separar reservas em duas agendas.

Confirmado em main.py; workers/arq_worker.py; services/calendar.py::from_tenant_config; local_calendar.py; services/precheck.py; config.py. Papel dos demais repositórios: PRODUCTS.md; código externo não auditado nesta entrega.

04 / ESTADO, SEGURANÇA E RESPONSABILIDADE

O que precisa continuar verdade entre mensagens.

O modelo entende a fala. O estado persistido e os serviços determinam o que de fato aconteceu.

DOMÍNIO	O QUE GUARDA	POR QUE IMPORTA
Clínica e profissionais	Configuração, catálogo, horários, unidades e credenciais separadas.	O atendimento usa a oferta real de cada clínica.
Paciente e conversa	Identidade do canal, mensagens, etapa e modo bot/humano.	Permite retomar sem reiniciar a conversa.
Consulta e rascunho	Escolhas em andamento, consulta efetiva, reserva temporária e agenda.	Uma intenção ainda não é uma consulta marcada.
Consentimentos	Registro de aceites e eventos de consentimento.	Documenta autorização dentro do fluxo.
Lembretes e entrega	Agendamento de avisos e estados de mensagens.	Ajuda a evitar repetição e acompanhar comunicação.
Sinal e conciliação	Cobrança, evento recebido, reservas e pendências financeiras.	Pagamento depende do provedor, não da fala da IA.

Antes da LLM

Histórico e resultados de ferramentas passam por pseudonimização. Identificadores conhecidos recebem marcadores; a resposta é reidratada antes do envio.

Isso reduz exposição; não equivale a anonimização completa ou prova de conformidade LGPD.

Dentro da plataforma

Segredos de integração são cifrados. Acesso interno e painel têm controles próprios. O contexto e as consultas devem respeitar clínica, papel e dono da agenda.

Nenhuma credencial, conversa real ou dado pessoal foi copiado para este documento.

> **O bot cede à equipe.** Coexistência e estado de atendimento humano impedem que o bot continue respondendo como se ainda fosse o responsável. Há rotinas de timeout e retomada.

models/__init__.py; models/conversation.py; services/pii_pseudonymization.py; ai/pii.py; ai/tool_output.py; services/sensitive_claim_guard.py; core/security.py; workers/shared/handover.py e workers/arq_worker.py. Existência de mecanismos não substitui auditoria de segurança em runtime.

05 / APIS E FORNECEDORES

Cada conexão tem um papel e uma conta.

A camada conversacional é só uma parte da operação. Há custos que não dependem de tokens.

CONEXÃO	USO NA SECRETARIA	COMO CONSIDERAR O CUSTO
Meta / WhatsApp Cloud API	Receber eventos, enviar texto, botões, listas, mídia e templates; coexistência com atendimento humano.	Mensagens elegíveis a cobrança por categoria, destino e tabela vigente. Lembretes podem ter cobrança mesmo sem LLM.
Anthropic / Messages API	Agente, ajuda delimitada e extração de fontes de contexto; padrão local Haiku 5.5.	Entrada, saída e cache. Requisições longas têm faixa própria.
Google Calendar + OAuth	Agenda externa por profissional ou conta compartilhada; disponibilidade e eventos.	Separar eventuais planos de conta e infraestrutura. O cenário não atribui tarifa fictícia por chamada.
OpenAI / Groq · áudio	Transcrição transforma a mensagem de voz em texto antes do fluxo normal.	Despesa de áudio separada da conversa Haiku. Modelo padrão local: gpt-4o-mini-transcribe.
SMTP	Códigos, convites, confirmação, avisos e comunicações operacionais.	Plano contratado e/ou preço por envio. Não requer tokens para textos fixos.
Cloudflare R2 / S3 API	Anexos do Portal, em armazenamento próprio da SecretarIA.	Armazenamento e operações; anexos não significam interpretação visual por IA.
Asaas / pagamentos	Sinal Pix, estado das cobranças e webhooks. A abstração admite outros provedores.	Tarifa de cobrança e condições da clínica. Não confundir valor do sinal com custo da plataforma.
brain-api / HTTP interno	Identidade, permissões, assinatura, provisionamento, Portal e ponte para PreCheck.	Rateio da plataforma compartilhada; PreCheck tem escopo e custos próprios.

A API de chat usa Anthropic quando a chave correspondente está configurada. Sem ela, com chave OpenAI disponível, o código usa OpenAI e registra o desvio. Não há troca automática por erro de Haiku para OpenAI nesse seletor.

ai/chat_model.py; config.py; services/calendar.py; services/media_storage.py; services/email.py; workers/whatsapp/audio.py; services/payments/; services/precheck.py. Regras de cobrança de mensagens: Meta · Pricing (consulta em 28/10/2026). Valores contratados não foram inspecionados.

06 / SUPERFÍCIES HTTP

A API organiza o produto em fronteiras claras.

Mapa funcional das rotas da SecretarIA. O inventário completo extraído do código está no apêndice.

SUPERFÍCIE	EXEMPLOS DE ROTAS	QUEM USA / FINALIDADE
Canal WhatsApp	`GET /webhook` `POST /webhook`	Meta valida e entrega eventos. Assinatura é verificada; processamento pesado vai à fila.
Canal Portal	`/internal/brain-message/*`	brain-api encaminha entradas, abertura, mensagens e sinais do canal.

Configuração e catálogo	`/tenants/me/configuration`
	`/tenants/me/services`
	`/tenants/me/professionals`
	`/tenants/me/insurance-plans`
		Painel da clínica mantém oferta, contexto e profissionais.

Agenda	`/tenants/me/calendar/events`
	`/tenants/me/calendar/appointments`
	`/tenants/me/calendar/blocks`
		Consultar e operar a agenda com escopo de acesso.

Conversas e equipe	`/tenants/me/conversations`
	`.../{conversation_id}/handover`
	`.../{conversation_id}/messages`
		Atendimento humano, histórico e mensagens da equipe.

Integrações e operações	`/oauth/*`
	`/webhooks/*`
	`/internal/*`
	`/tenants/me/payment-*`
		Google, pagamentos, provisionamento, privacidade e operação entre serviços.

Saúde e observabilidade	`/health` `/build`	Verificar processo e identidade de build. API e worker precisam estar na versão adequada.

Resposta rápida ao canal

O webhook WhatsApp verifica, reduz o payload e enfileira. Se a fila não está disponível, devolve indisponibilidade para permitir reentrega.

Pagamento exige durabilidade

O webhook de pagamento por provedor persiste o evento antes de aceitar. A confirmação financeira é reconciliada com o provedor.

main.py registra os routers. O apêndice combina os prefixos de APIRouter com seus decorators HTTP por AST, sem carregar a aplicação ou segredos. Rotas padrão do framework (/docs, /redoc, /openapi.json) não entram na contagem.

07 / ECONOMIA DA INTELIGÊNCIA

Quanto custa uma chamada de Haiku?

Premissas de orçamento, com a versão encontrada no código: claude-haiku-5-5.

ENTRADA / 1M TOKENS

US$ 0,10

Prompt por requisição até 100 mil tokens.

SAÍDA / 1M TOKENS

US$ 0,50

Usar a saída faturável completa, inclusive thinking quando cobrado.

CÂMBIO ILUSTRATIVO

R$ 5,50

Por US$ 1. Não é cotação de mercado, nem inclui tributos/spread.

Uma chamada do cenário central

COMPONENTE	PREMISSA	CUSTO EM US$
Entrada completa	8.000 tokens	0,0008
Saída faturável	1.000 tokens	0,0005
Total por requisição	Sem desconto de cache	**0,0013 = R$ 0,00715**

> **"Mensagem" e "chamada" são diferentes.** Um turno pode gerar Haiku → ferramenta → Haiku. Cada requisição reenvia parte do contexto, das instruções e das definições das ferramentas; tudo isso deve entrar nos tokens de entrada.

O que pode mudar a conta

O código limita o histórico a 30 mensagens no agente e 10 na ajuda delimitada. Isso não é um limite de tokens. O teto local de saída Haiku é 16.000 por chamada, incluindo thinking; não representa consumo médio.

Cache já está previsto

O prompt do sistema recebe marca de cache efêmero. Orçamentamos sem hits: gravação de 5 min custa US$ 0,125/M e leitura US$ 0,01/M. Eficiência real depende da repetição do prefixo.

Acima de 100 mil tokens de prompt por requisição, a tabela passa a US$ 0,50/M de entrada e US$ 2,50/M de saída. O limite é por requisição, não pela soma do mês. Os cenários seguintes usam a faixa menor.

Tarifas: Anthropic · Pricing; modelo: Haiku 5.5 (28/10/2026). Código: config.py; ai/chat_model.py; ai/graph.py; ai/scoped_help.py. Tokens são hipóteses, sem medição de produção.

08 / CUSTO POR RESULTADO

Da chamada barata à consulta marcada.

Uma previsão útil considera ativação da IA, volume de chamadas e conversão em agendamento.

```
Custo LLM / consulta = (p ÷ q) × k × c
c = câmbio × [(entrada × tarifa_in + saída × tarifa_out) ÷ 1.000.000]
```

p: fração das conversas com IA. **q:** consultas novas marcadas por conversa iniciada (simplificação do cenário: no máximo uma). **k:** requisições médias de modelo por conversa com IA, somando todos os turnos e loops. **c:** custo médio de uma requisição. Conversas sem agendamento permanecem no numerador.

PREMISSA	LEVE	CENTRAL	INTENSIVO
Conversas com IA (p)	15%	35%	65%
Conversão (q)	75%	60%	40%
Requisições (k)	2	3	6
Tokens / requisição	4 mil in + 500 out	8 mil in + 1 mil out	16 mil in + 2 mil out
LLM / consulta	**R$ 0,00143**	**R$ 0,01251**	**R$ 0,13943**
LLM / 1.000 consultas	R$ 1,43	R$ 12,51	R$ 139,43

Escala de despesa para 1.000 consultas



Orçamento central com reserva de 30%: aproximadamente **R$ 0,01627 por consulta** ou **R$ 16,27 por 1.000**, somente LLM. A reserva é uma hipótese de planejamento para variações, gravações de cache e repetições; não é teto garantido.

Cálculos próprios com tarifas da página anterior. Não são intervalos estatísticos, amostra real ou promessa de preço. No central: US$ 0,0013 × 3 × 5,50 × (0,35/0,60) = R$ 0,0125125.

09 / LABORATÓRIO DE CUSTOS

Mude as premissas. Veja o efeito na hora.

Na versão HTML, os campos recalculam o orçamento localmente. No PDF, esta página registra o cenário central.

Consultas marcadas / mês	Conversas com IA (%)	Conversão em consulta (%)
1000	35	60
Requisições / conversa com IA	**Tokens de entrada / requisição**	**Tokens de saída / requisição**
3	8000	1000
R$ / US$ (hipótese)	**Reserva de orçamento (%)**	**Custos fixos rateados / mês (R$)**
5.5	30	0

LLM / CONSULTA · SEM RESERVA

R$ 0,01251

Inclui conversas sem agendamento.

LLM / MÊS · COM RESERVA

R$ 16,27

1.000 consultas marcadas.

O funil implícito neste cenário

1.667 conversas iniciadas → 583 com IA → 1.750 requisições → 1.000 consultas.

LLM com reserva + fixos informados: R$ 0,01627 por consulta. Outros custos variáveis não incluídos.

"Fixos = 0" significa não informado. Preencha o rateio real de hospedagem, banco, Redis, observabilidade e plataforma. O total mostrado ainda não inclui mensagens cobradas, áudio, e-mail, anexos, pagamentos, suporte ou tributos.

Faixa usada: prompts até 100.000 tokens. Sem desconto de cache; sem tributos e spread.

Simulador offline, sem envio de dados, sem analytics e sem dependências externas. Ao alterar a entrada acima de 100 mil tokens, aplica a faixa maior do Haiku 5.5. Valores médios não modelam uma mistura de requisições nas duas faixas.

10 / O CUSTO QUE O TOKEN NÃO MOSTRA

O custo total depende da operação inteira.

A economia da LLM não torna a consulta gratuita. O custo total exige volumes e contratos reais.

```
Custo total / consulta =
LLM + canal + áudio + e-mail + arquivos + pagamentos
+ [(infra + plataforma + suporte) ÷ consultas marcadas]
```

CAMADA	COMO MEDIR	TRATAMENTO NESTE ESTUDO
LLM de paciente	Soma de requisições, cache e saída faturável.	Estimativa explícita em três cenários.
LLM administrativa	Extração/preparação de fontes da clínica.	Separar como onboarding/manutenção e depois ratear.
Mensageria	Mensagens efetivamente cobradas × tarifa aplicável.	Sem tarifa Brasil inventada. Gratuidade depende da categoria e janela vigente.
Áudio e anexos	Uso de transcrição, armazenamento e operações.	Não entram na conta Haiku.
E-mail	Envios e plano contratado.	Valor contratual não informado.
Pagamentos	Cobranças e tarifa do provedor.	Separar quem absorve a tarifa: clínica ou plataforma.
Infra + equipe	API, worker, Postgres, Redis, monitoramento e suporte.	Rateio por volume; requer despesas reais.

EXEMPLO ARITMÉTICO · NÃO É COTAÇÃO

R$ 0,5163

Por consulta com 1.000/mês, se o rateio fixo hipotético for R$ 500 e a LLM central com reserva custar R$ 16,27/mês. Demais variáveis excluídas.

MESMO FIXO · 10.000 CONSULTAS/MÊS

R$ 0,0663

R$ 500 ÷ 10.000 + R$ 0,01627 de LLM com reserva. Mantém o fixo por hipótese; capacidade real pode exigir expansão.

O sinal Pix não é receita automática da SecretarIA. É valor pago pelo paciente à clínica, conforme a configuração e a conta do provedor. A tarifa de recebimento e a mensalidade do SaaS são contas diferentes.

Componentes observados em config.py, main.py, workers/arq_worker.py e serviços de integrações. Exemplo de R$ 500 é hipotético e não representa fatura, plano recomendado ou capacidade garantida.

11 / CONFIABILIDADE E PRÓXIMOS INDICADORES

Acompanhe o resultado. Depois calibre a previsão.

A melhor decisão é preservar a jornada guiada e medir o gasto de todas as saídas do funil.

01 · Duas versões em operação	API e worker são serviços separados. Uma API saudável não prova que o worker está na mesma versão. A identidade de build e a comparação de paridade existem para detectar essa diferença.
02 · Falha não pode virar sucesso fictício	Há proteções de saída, escopo de ferramentas, tratamento de agenda indisponível e resposta fixa quando o turno não entrega texto. Não equivalem a garantia absoluta contra erro do modelo.
03 · Consultar o provedor é essencial	Reserva, cobrança criada e pagamento identificado são etapas distintas. Webhooks duplicados e reconciliação precisam ser tratados sem criar outra consulta ou outra cobrança.
04 · Métrica já disponível, com lacunas	O agente registra modelo, chamadas, ferramentas, tokens e tempo em `llm_turn_trace`; a ativação registra motivo. A ajuda delimitada e a extração não têm, neste estudo, cobertura financeira equivalente comprovada.

O painel mínimo para trocar hipótese por média

Conversão
Conversas iniciadas, novas consultas, abandono e encaminhamento humano.

Ativação
% com IA, motivo, requisições por conversa e retorno aos botões.

Conta real
Entrada normal, cache gravado/lido, saída e thinking já incluído na saída.

> **Média observada = gasto atribuído à coorte ÷ consultas novas marcadas pela coorte.** Uma remarcação não é outra aquisição. Deduplicar reentregas e amarrar conversas às consultas evita custo artificialmente baixo. Também acompanhar custo por consulta comparecida.

Sugestão de medição: janela inicial de 30 dias, com corte por clínica e canal. Fechar a coorte após prazo definido para agendamento tardio. Conciliar com faturamento do fornecedor e incluir chamadas que falham, retries faturados e saídas por ferramentas. Separar uso administrativo e PreCheck.

ai/trace.py e ai/graph.py::_log_agent_trace; workers/shared/llm_context.py; core/build_info.py; services/payments/. Leitura do código não comprova completude de logs nem consumo faturado. Instrumentação adicional foi recomendada, não implementada.

12 / EVIDÊNCIA E LEITURA CORRETA

O que foi verificado. O que ainda é hipótese.

Este dossiê combina engenharia confirmada no checkout com planejamento econômico parametrizado.

> **Base reprodutível:** repositório SecretarIA, branch `main`, commit `c9b6ba2d7677`, leitura em 28/10/2026. O Git já continha alterações do usuário em CLAUDE.md e AGENTS.md; elas foram preservadas. Graphify estava STALE e foi usado apenas como navegação histórica.

S01 · Entrada e implantação

`src/secretaria/main.py; src/secretaria/api/webhook.py; src/secretaria/workers/arq_worker.py`
API, webhook, fila, worker e rotinas agendadas.

S02 · Jornada e decisão

`src/secretaria/services/flow_router.py; src/secretaria/workers/turn_router.py; src/secretaria/workers/orchestrator.py`
Fluxo guiado, delegação à IA e efeitos do turno.

S03 · Modelo e tokens

`src/secretaria/config.py; src/secretaria/ai/chat_model.py; src/secretaria/ai/graph.py; src/secretaria/ai/trace.py; src/secretaria/ai/scoped_help.py`
Haiku 5.5, seleção por chave, cache, histórico e rastros de uso.

S04 · Dados, agenda e privacidade

`src/secretaria/models/; src/secretaria/services/calendar.py; src/secretaria/services/local_calendar.py; src/secretaria/ai/pii.py; src/secretaria/services/pii_pseudonymization.py`
Estado, escolha de backend e pseudonimização.

S05 · Integrações

`src/secretaria/services/media_storage.py; src/secretaria/services/email.py; src/secretaria/services/precheck.py; src/secretaria/workers/whatsapp/audio.py; src/secretaria/services/payments/`
Anexos, e-mail, áudio, PreCheck e sinal.

S06 · Contexto operacional

`../PRODUCTS.md; AGENTS.md; CLAUDE.md; docs/CHECKPOINT_llm_provider_claude.md; docs/CHECKPOINT_sinal_padrao.md`
Mapa entre produtos e histórico de decisões. Checkpoints podem descrever estados anteriores ao HEAD atual.

W01 · Tarifas e modelo · consulta em 28/10/2026

Anthropic · tabela oficial de preços · Haiku 5.5 · referência do modelo

W02 · Canal · consulta em 28/10/2026

Meta · WhatsApp Business Platform Pricing. Revalidar tabela e condições antes de fechar orçamento comercial.

Limites: sem consulta a produção, banco remoto, variáveis de ambiente ou faturas; sem execução paga de modelos. Não foram medidos ativação, conversão, tokens médios ou disponibilidade efetiva por clínica. O padrão de configuração não comprova o modelo efetivo de produção. Não houve commit, push ou deploy. APIs de brain-api e PreCheck não foram inventariadas; o apêndice cobre apenas a SecretarIA.

APÊNDICE / INVENTÁRIO 01

Rotas da SecretarIA.

107 operações HTTP explícitas registradas em main.py. Nesta página: 1 a 22.

Método + caminho efetivo + módulo responsável. Inventário estático do código local, sem sondagem de serviços. Corpo, resposta e dependências de autenticação devem ser consultados nos schemas e na OpenAPI do build correspondente.

MÉTODO	ROTA	MÓDULO EM API/
POST	/admin/insurance-catalog	admin.insurance
GET	/admin/insurance-catalog/unmatched	admin.insurance
POST	/admin/reset	admin.panel
GET	/admin/tenants	admin.tenants
DELETE	/admin/tenants/{tenant_id}	admin.tenants
GET	/admin/tenants/{tenant_id}/calendar/health	admin.tenants
POST	/admin/tenants/{tenant_id}/calendar/sync-local	admin.tenants
GET	/build	health
GET	/health	health
GET	/internal/brain-message/conversations/{external_id}/messages	internal
POST	/internal/brain-message/inbound	internal
GET	/internal/brain-message/insurance-overview	internal
GET	/internal/brain-message/media/{message_id}	internal
POST	/internal/brain-message/messages/read	internal
POST	/internal/brain-message/open	internal
POST	/internal/brain-message/typing	internal
POST	/internal/brain-message/visits/discard	internal
POST	/internal/brain-message/visits/merge	internal
POST	/internal/notifications/email	internal_provisioning
DELETE	/internal/privacy/tenants/{tenant_id}/subjects/{wa_id}	internal_privacy
GET	/internal/privacy/tenants/{tenant_id}/subjects/{wa_id}/export	internal_privacy
POST	/internal/tenants	internal_provisioning

Extração AST: módulos importados por main.py + include_router + prefixo do APIRouter + decorators HTTP. Fonte por função/linha disponível no arquivo inventario-apis.json. Não inclui documentação automática do FastAPI, rotas de outros produtos ou contratos não registrados.

APÊNDICE / INVENTÁRIO 02

Rotas da SecretarIA.

107 operações HTTP explícitas registradas em main.py. Nesta página: 23 a 44.

Método + caminho efetivo + módulo responsável. Inventário estático do código local, sem sondagem de serviços. Corpo, resposta e dependências de autenticação devem ser consultados nos schemas e na OpenAPI do build correspondente.

MÉTODO	ROTA	MÓDULO EM API/
POST	/internal/tenants/{tenant_id}/activate	internal_provisioning
GET	/internal/tenants/{tenant_id}/appointments	internal
POST	/internal/tenants/{tenant_id}/asaas-connection	internal_provisioning
GET	/internal/tenants/{tenant_id}/config-status	internal_provisioning
POST	/internal/tenants/{tenant_id}/patient-cleanup	internal_patient_cleanup
GET	/internal/tenants/{tenant_id}/patient-cleanup/preview	internal_patient_cleanup
GET	/internal/tenants/{tenant_id}/patients	internal
GET	/internal/tenants/{tenant_id}/professionals	internal_provisioning
POST	/internal/tenants/{tenant_id}/professionals	internal_provisioning
POST	/internal/tenants/{tenant_id}/whatsapp-connection	internal_provisioning
GET	/oauth/google/callback	hub.oauth
GET	/tenants/me/analytics/advanced	hub.analytics
GET	/tenants/me/analytics/summary	hub.analytics
POST	/tenants/me/calendar/appointments	hub.calendar
POST	/tenants/me/calendar/appointments/{appointment_id}/cancel	hub.calendar
GET	/tenants/me/calendar/appointments/{appointment_id}/cancel-preview	hub.calendar
POST	/tenants/me/calendar/appointments/{appointment_id}/edit	hub.calendar
POST	/tenants/me/calendar/appointments/{appointment_id}/message	hub.calendar
POST	/tenants/me/calendar/appointments/{appointment_id}/release	hub.calendar
POST	/tenants/me/calendar/appointments/{appointment_id}/reschedule	hub.calendar
PATCH	/tenants/me/calendar/appointments/{appointment_id}/status	hub.calendar
GET	/tenants/me/calendar/awaiting-payment	hub.calendar

Extração AST: módulos importados por main.py + include_router + prefixo do APIRouter + decorators HTTP. Fonte por função/linha disponível no arquivo inventario-apis.json. Não inclui documentação automática do FastAPI, rotas de outros produtos ou contratos não registrados.

APÊNDICE / INVENTÁRIO 03

Rotas da SecretarIA.

107 operações HTTP explícitas registradas em main.py. Nesta página: 45 a 66.

Método + caminho efetivo + módulo responsável. Inventário estático do código local, sem sondagem de serviços. Corpo, resposta e dependências de autenticação devem ser consultados nos schemas e na OpenAPI do build correspondente.

MÉTODO	ROTA	MÓDULO EM API/
POST	/tenants/me/calendar/blocks	hub.calendar
POST	/tenants/me/calendar/disconnect	hub.oauth
GET	/tenants/me/calendar/events	hub.calendar
GET	/tenants/me/calendar/health	hub.oauth
GET	/tenants/me/calendar/oauth/start	hub.oauth
GET	/tenants/me/calendar/viewer	hub.calendar
GET	/tenants/me/config	hub.config
PUT	/tenants/me/config	hub.config
PUT	/tenants/me/configuration	hub.config
GET	/tenants/me/context-completeness	hub.context_completeness
GET	/tenants/me/context-sources	hub.context_sources
POST	/tenants/me/context-sources	hub.context_sources
POST	/tenants/me/context-sources/file	hub.context_sources
DELETE	/tenants/me/context-sources/{source_id}	hub.context_sources
GET	/tenants/me/context-sources/{source_id}	hub.context_sources
GET	/tenants/me/conversations	hub.conversations
POST	/tenants/me/conversations/{conversation_id}/handover	hub.conversations
GET	/tenants/me/conversations/{conversation_id}/messages	hub.conversations
POST	/tenants/me/conversations/{conversation_id}/messages	hub.conversations
POST	/tenants/me/conversations/{conversation_id}/messages/read	hub.conversations
GET	/tenants/me/conversations/{conversation_id}/messages/{message_id}/media	hub.conversations
GET	/tenants/me/conversations/{conversation_id}/typing	hub.conversations

Extração AST: módulos importados por main.py + include_router + prefixo do APIRouter + decorators HTTP. Fonte por função/linha disponível no arquivo inventario-apis.json. Não inclui documentação automática do FastAPI, rotas de outros produtos ou contratos não registrados.

APÊNDICE / INVENTÁRIO 04

Rotas da SecretarIA.

107 operações HTTP explícitas registradas em main.py. Nesta página: 67 a 88.

Método + caminho efetivo + módulo responsável. Inventário estático do código local, sem sondagem de serviços. Corpo, resposta e dependências de autenticação devem ser consultados nos schemas e na OpenAPI do build correspondente.

MÉTODO	ROTA	MÓDULO EM API/
POST	/tenants/me/conversations/{conversation_id}/typing	hub.conversations
GET	/tenants/me/insurance-catalog	hub.insurance
GET	/tenants/me/insurance-mode	hub.insurance
PUT	/tenants/me/insurance-mode	hub.insurance
GET	/tenants/me/insurance-plans	hub.insurance
PUT	/tenants/me/insurance-plans	hub.insurance
POST	/tenants/me/insurance-plans/custom	hub.insurance
PATCH	/tenants/me/insurance-plans/{plan_id}	hub.insurance
GET	/tenants/me/payment-accounts	hub.payment_accounts
DELETE	/tenants/me/payment-accounts/asaas	hub.payment_accounts
PUT	/tenants/me/payment-accounts/asaas/connection	hub.payment_accounts
POST	/tenants/me/payment-accounts/asaas/retry-webhook	hub.payment_accounts
GET	/tenants/me/payment-attention-items	hub.payment_attention
POST	/tenants/me/payment-attention-items/{item_id}/resolve	hub.payment_attention
GET	/tenants/me/payment-settings	hub.payment_settings
GET	/tenants/me/professionals	hub.professionals
POST	/tenants/me/professionals	hub.professionals
POST	/tenants/me/professionals/calendars	hub.professionals
PATCH	/tenants/me/professionals/{professional_id}	hub.professionals
POST	/tenants/me/professionals/{professional_id}/calendar	hub.professionals
POST	/tenants/me/professionals/{professional_id}/calendar/disconnect	hub.oauth
GET	/tenants/me/professionals/{professional_id}/calendar/oauth/start	hub.oauth

Extração AST: módulos importados por main.py + include_router + prefixo do APIRouter + decorators HTTP. Fonte por função/linha disponível no arquivo inventario-apis.json. Não inclui documentação automática do FastAPI, rotas de outros produtos ou contratos não registrados.

APÊNDICE / INVENTÁRIO 05

Rotas da SecretarIA.

107 operações HTTP explícitas registradas em main.py. Nesta página: 89 a 107.

Método + caminho efetivo + módulo responsável. Inventário estático do código local, sem sondagem de serviços. Corpo, resposta e dependências de autenticação devem ser consultados nos schemas e na OpenAPI do build correspondente.

MÉTODO	ROTA	MÓDULO EM API/
PUT	/tenants/me/professionals/{professional_id}/config	hub.professionals
GET	/tenants/me/professionals/{professional_id}/insurance-plans	hub.insurance
PUT	/tenants/me/professionals/{professional_id}/insurance-plans	hub.insurance
POST	/tenants/me/professionals/{professional_id}/insurance-plans/custom	hub.insurance
GET	/tenants/me/release-offers	hub.release_offers
POST	/tenants/me/release-offers/{offer_id}/keep/accept	hub.release_offers
POST	/tenants/me/release-offers/{offer_id}/keep/refuse	hub.release_offers
POST	/tenants/me/release-offers/{offer_id}/refunded	hub.release_offers
GET	/tenants/me/services	hub.services
POST	/tenants/me/services	hub.services
PATCH	/tenants/me/services/{service_id}	hub.services
POST	/tenants/me/simulation/turn	hub.simulation
GET	/tenants/me/units	hub.units
POST	/tenants/me/units	hub.units
PATCH	/tenants/me/units/{unit_id}	hub.units
GET	/webhook	webhook
POST	/webhook	webhook
POST	/webhooks/asaas	webhook_asaas
POST	/webhooks/{provider}/{webhook_slug}	webhook_payments

Extração AST: módulos importados por main.py + include_router + prefixo do APIRouter + decorators HTTP. Fonte por função/linha disponível no arquivo inventario-apis.json. Não inclui documentação automática do FastAPI, rotas de outros produtos ou contratos não registrados.